

Fit Over Depth: Transfer Appropriate Compression for LongContext LLM QA

CUIAI 9기 NLP 1팀
노지우(영어영문학과)

[요약] 인간의 기억 강화 전략(정교화 되뇌기·검사효과·유지형 되뇌기)을 롱컨텍스트 LLM QA에 이식해 4개 장르 579문항으로 검증했다. 인간의 인지 강화 이론을 적용한 다양한 모델을 시도한 결과 유지형 되뇌기에 국소 이음매 복구를 결합한 최종 모델은 RAG와 정답 개수까지 일치하면서 토큰은 14% 절약했다.

에서 출발해 유지형 되뇌기에 문서 길이 적응 압축률과 국소 이음매 복구(local coherence repair)를 결합한 최종 모델을 제안한다(본론 3). 이 모델은 RAG와 정답 개수까지 정확히 일치하면서(254/579) 토큰은 14% 더 적게 썼다(본론 4).

1. 서론

장문의 컨텍스트를 LLM에 입력하면 정보를 놓칠 것이라는 통념이 있다. 그러나 본 연구의 사전 실험(4개 장르 607 문항, 1,000~50,000단어)에서는 문서 길이에 따른 정답률 저하가 나타나지 않았다. 10,000단어 문서에 근거가 있는 143문항을 고정한 채 뒤에 40,000단어를 덧붙였을 때, 정답률 순변화는 +2(약 1.4%p)에 그쳤다. 대신 드러난 것은 활용의 문제였다. 뉴스 장르는 모델의 사전지식이 사실상 없는데도(closed-book 정답률 0에 근접) 원문 전체를 그대로 입력해도 정답률이 0.4를 넘지 못했다[1]. 정답이 본문에 있어도 모델은 상당 부분을 놓친다.

본 연구는 이 활용 격차를 인간의 기억 강화 전략으로 좁힐 수 있는지 묻는다(RQ1). 다만 인간 기억 연구의 세 전략 — 정보를 기존 지식과 연결지어 재구성하는 정교화 되뇌기(elaborative rehearsal), 다시 읽지 않고 기억에서 인출을 연습하는 검사효과(testing effect), 정보를 가공 없이 그대로 반복하는 유지형 되뇌기(maintenance rehearsal) — 이 예측하는 방향은 서로 엇갈린다. 이 불일치를 두 질문으로 나눈다. 전략이 콘텐츠를 재작성하는지 보존하는지가 애초에 작동 여부를 가르는가(RQ2a). 그리고 재작성 없이 살아남은 전략들 사이에서는, 부호화 방식이 문서 구조에 맞는지가 우열을 가르는가(RQ2b).

이 질문에 답하기 위해 본 연구는 정교화 되뇌기를 가장 먼저 구현해 검증했다(본론 1). 처리수준 이론[20]이 가장 큰 효과를 예측하는 전략이다. 이 전략은 모델 크기와 무관하게 구조적으로 붕괴해 순수 검색 증강(retrieval-augmented generation, RAG)에 뒤졌다(본론 2). 이 진단

2. 본론

1) 파이프라인과 첫 시도: 정교화 되뇌기

Craik & Lockhart(1972)의 처리수준 이론[20]은, 정보를 의미 중심으로 깊이 처리할수록(elaboration) 표면적으로만 반복하는 얇은 처리(maintenance)보다 장기 기억에 항상 유리하다고 예측한다. 본 연구는 이 예측을 따라 세 전략 중 정교화 되뇌기를 가장 먼저 구현·검증할 가설로 삼았다. 이 장은 그 파이프라인 전체와 첫 번째로 시도한 정교화 되뇌기의 구조·학습 방법을 설명한다.

[청킹] 인접한 두 의미 단위(문단 또는 문장) 사이의 임베딩 코사인 유사도가 가장 낮은 지점에서 분할한다. 문장·대사 묶음의 무결성과 저자가 명시한 장면전환 지점은 이 기준보다 항상 우선시되며, 각 청크는 min_words, max_word를 넘지 않도록 설정한다.

$$s_i = \cos(e_i, e_{i+1}) \quad (1)$$
$$i^* = \arg \min_{\min_words \leq i \leq \max_words} s_i \quad (2)$$

[정교화 되뇌기 학습] 정교화 되뇌기를 가설로서 먼저 구현했다. 청크를 순서대로 처리하며 현재 청크 C_i 와 누적 요약 S_{i-1} 을 받아 갱신된 요약 S_i 를 생성한다. 기존 요약에 이어붙이지 않고 고쳐쓰는 구조다[3][5]. t5-small은 두 단계로 학습했다. 1단계는 XSum 기반 one-shot 압축을 지도학습한다. 2단계는 실제 추론과 동일한 rolling 구조를 70B teacher(meta/llama-3.1-70b-instruct)가 재현한 데이터(336건)로 재학습한다.




그림 1 첫 시도한 파이프라인 구조: 청킹 → 정교화 되뇌기(스레드 메모리 조화·갱신) → 최종 QA(gist 우선 응답, 불충분하면 Adaptive-k로 원문 재조회).

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_i \log P(\theta(S_i | C_i, S_i - 1)) \quad (3)$$

이는 C-DIC[3]의 삽입/갱신 규칙을 텍스트 레벨로 확장해 여러 주제 스레드의 압축 상태 Z_j 를 유지하며 현재 청크와 가장 유사한 스레드를 조화·갱신하는 방식이다.

$$\delta_t = \max_j \text{sim}(C_t, Z_j) \quad (4)$$

$$M_{t+1} = \begin{cases} M_t \cup Z_t & \delta_t < \tau \text{ (신규 삽입)} \\ (M_t \setminus Z_j^*) \cup Z_t & \delta_t \geq \tau \text{ (기존 교체)} \end{cases} \quad (5)$$

이 스레드 조화·갱신 구조가 뒤에서(본문 2) 정교화 되뇌기의 실패 원인으로 지목된다.

[최종 QA와 Adaptive-k 재조회] 최종 QA는 먼저 모든 청크의 gist로 응답을 시도한다. Gist 내용만으로 불충분하면 특정 청크의 원문을 2차 호출로 재조회한다(lookup)[4]. 재조회 대상은 질문과 청크 gist 사이의 유사도로 정한다.

$$\text{score}(q, C_i) = \cos(\text{embed}(q), \text{embed}(C_i)) \quad (6)$$

장르별로 고정된 재조회 개수를 직접 정하는 대신 Adaptive-k[8]의 gap 기반 임계값을 적용한다. 유사도 순위를 내림차순 정렬한 뒤 인접 순위 간 낙차가 가장 큰 지점까지만 재조회한다(식 7).

$$\text{gap}(i) = s(i) - s(i+1), \quad k^* = \arg \max_i \text{gap}(i) \quad (7)$$

[실험 설정] 4개 장르(위키(SQuAD[11]), 뉴스(NewsQA[12]), 소설(NarrativeQA[9]), 판례(CaseHOLD, LexGLUE[10])) 총 579문항으로 검증했다(표 1). 위키·뉴스·소설은 EM/F1로, 판례는 5지선다 정확도로 채점한다. 베이스라인은 closed_book과 full_context이다. 비교 조건은 정교화 되뇌기 기반으로 look_up/look_up+retrieval, 그리고 순수 검색 증강(이하 RAG)이다. RAG는

학습·압축 없이 Adaptive-k만으로 원문을 그대로 가져온다.

표 1 실험에 사용한 4개 장르의 데이터 소스·문항 수·채점 방식

장르	데이터 소스	문항 수	채점 방식
위키	SQuAD[11]	100	EM / F1
뉴스	NewsQA[12]	200	EM / F1
소설	NarrativeQA[9]	79	EM / F1
판례	CaseHOLD (LexGLUE[10])	200	5 지선다 정확도

표 2 RAG와 정교화 되뇌기 계열의 전체 스케일 비교 (n=579)

조건	위키	뉴스	소설	판례	정답률
원문 전체	0.810	0.395	0.494	0.360	0.515
정교화 되뇌기+재조회	0.620	0.220	0.291	0.245	0.339
RAG	0.850	0.420	0.316	0.300	0.439

표 3 정교화 되뇌기 붕괴 완화 3조건의 위키 정답률 (n=100)

조건	정답률
붕괴 상태(BASELINE)	0.130
+ 붕괴 감지 시 CONTEXT 없이 재생성	0.390
+ CONTRASTIVE DECODING	0.330
ADAPTIVE-K 검색(RAG)	0.850

표 4 스레드 메모리 붕괴(의도한 동작과 실제 동작의 비교)

구분	입력	출력 Z_{t}
의도한 동작	$C_t + Z_{j^*}$	두 내용을 통합한 새 요약
실제 동작	$C_t + Z_{j^*}$	Z_{j^*} 의 내용만 그대로 복제 (C_t 미반영)
슬롯 교환 테스트	$Z_{j^*} + C_t$ (역할 교환)	여전히 기존 스레드 내용만 복제

2) 정교화 되뇌기 조건의 한계

전체 스케일(n=579)에서 RAG는 첫 시도인 정교화 되뇌기 기반 최고 조건(lookup+retrieval)을 정답률·토큰 비용 양쪽에서 앞섰다(표 2). 파일럿 규모(장르당 15문항)에서 관찰된 신호가 표본을 확장해도 뒤집히지 않고 오히려 이 신호는 두드러진다.

정교화 되뇌기의 활용 실패 원인을 세 단계로 좁혔다.

(1) 먼저 구조와 내용을 분리했다. RAG와 동일한 Adaptive-k 기반 재조회 청크 선정 구조에서 내용만 원문 기준에서 gist로 바꾼 조건은 정답률이 0.121까지 떨어




그림 2 최종 제안 모델의 아키텍처: 청크(원문) → 유지형 되뇌기(RoBERTa 문장 점수화, 동적 압축률) → 국소 이음매 복구(선택 문장 앞뒤 window=1 패딩) → 최종 압축 컨텍스트. 2장의 첫 시도(정교화 되뇌기)와 달리 전 과정에서 원문 문장을 재작성하지 않는다.

졌다. (2)다음으로 재조회 청크 선정 기준을 gist 임베딩으로 바꿔도 결과는 거의 같았다(0.119) 이는 원인이 재조회 청크 선정이 아니라 gist 내용 자체에 있음을 알려준다. 마지막으로 모델 크기 통제를 통해 진단했다.

Teacher(7B)로 동일한 retrieve-and-replace 구조를 재현했다. 서로 다른 원문에서 나온 청크의 gist 대부분이 동일한 문장으로 수렴했다. 최소 통제 예제에서 "현재 청크"와 "관련 스레드" 슬롯을 서로 바꿔도 결과는 같았다. 모델은 관련 스레드의 내용만 그대로 복제하고 현재 청크는 반영하지 않았다(vy 4). 이 붕괴는 t5-small과 teacher(70B) 모두에서 재현됐다. 모델 크기와 무관하게 retrieve-and-replace 설계 자체가 실패했다.

이 결과(표 4)는 선행 보고 셋과 방향이 같다. 추출적 압축이 생성적 압축보다 RAG 성능에서 우수하다는 보고[17], query-aware 압축이 query-agnostic보다 우수하다는 보고[18], 그리고 생성 요약 없이 원문 순서를 그대로 보존하는 단순 검색(DOS RAG)이 RAPTOR류의 트리 요약 파이프라인을 오히려 능가한다는 보고[25]다. 정교화 되뇌기는 질문을 보지 않고 재작성하는 생성적 압축이므로 세 불리한 조건을 모두 가진 셈이다. 다음 장에서 이 진단에서 직접 도출한 최종 제안 모델을 다룬다.

다만, 이 실패는 구조적이지만 재학습 없이 추론 시점 개입만으로 완화할 수 있는지는 별도로 검증했다(위키 장르, 100문항, 표 3). 붕괴된 출력(자신이 검색한 context 대비 novelty가 낮은 경우)을 감지해 context 없이 재생성하거나, context만 있었을 때 예측했을 법한 연속을 억제하는 contrastive decoding을 쓰면 둘 다 붕괴 baseline을 크게 웃돌지만 여전히 Adaptive-k 검색에는 못 미쳤으며 이를 통해 실패는 압축기의 능력이 아니라 검색과 생성이 결합되는 방식에 있음을 확인할 수 있다. 본 연구의 최종 모델(본문 3)이 이 복구 방식에 의존하지는 않지만 이 결과는 이 아키텍처가 이론적으로는 수리 가능함을 시사한다.

3) 최종 모델: 전이적합추출+국소 이음매 복구

본문 2의 진단이 지목한 원인은 재생성 단계 자체였다. 문장을 재작성하지 않고 고르기만 하는 전략은 이 붕괴가 발생하지 않는다. 따라서 최종 제안 모델은 유지형 되뇌기에 문서 길이 적응 압축률과 국소 이음매 복구를 결합한 모델(이하 전이적합추출, transfer-appropriate extraction)이다. 이는 모델의 추출 방식이 전이적합처리 이론[21]과 정합적이라는 의미에서 붙인 이름이다.

[재작성 없는 전략만이 살아남는다] 유지형 되뇌기는 청크 내부에서 중요 문장을 RoBERTa 점수기로 골라 원문 그대로 유지하며 청크 간 통합은 하지 않는다. 이 조건을 RAG와 동일한 Adaptive-k 청크 선정에 결합해 재검증했다.

[동적 압축률] 압축률을 고정($R=0.3 \rightarrow 0.5$)하는 것만으로 정답률이 오른다($0.325 \rightarrow 0.368$). 이는 유실되는 근거 문장 비율이 43%에서 26%로 줄기 때문이다. gist는 예산을 늘려도 붕괴 때문에 정답률이 하락한 반면, 유지형 되뇌기는 원문 그대로 추출하기 때문에 예산 증가와 정답률이 정적 관계를 보인다.

장르-문서 길이에 맞춰 압축률을 동적으로 정할 때(Sie et al. 2024[17]의 dependent-ratio, 목표 토큰 예산 32,000) 가장 크게 개선됐다.

$$R = \min\left(1, \frac{K}{|D|}\right), \quad K = 32,000 \quad (8)$$

전체 정답률 0.428로 RAG(0.439)와 격차가 0.011까지 좁혀졌고 토큰 사용량은 RAG의 절반(1,862 대 3,588) 수준이다. 위키 장르에서는 RAG의 정답률을 증가했다(0.880 대 0.850).

[남은 격차: 추출은 이음매를 만든다] 동적 압축률만으로 해소되지 않는 격차가 남았다. 서사 연속성에 의존하는 소설 장르에서 이 특징이 더욱 두드러진다(0.278 대 0.316). 추출 과정에서 원문에서 서로 붙어있지 않던 문장을 이어 붙이므로 필연적으로 문맥이 끊긴다. Kintsch

(1988)[22]의 Construction-Integration 모델은 이해를 명제들 사이의 국소적 연결로 텍스트베이스를 구성하는 과정으로 본다. Kintsch는 인간의 텍스트 이해 과정에서 연결에 필요한 명제가 없으면 독자는 다리 놓기 추론(bridging inference)을 수행한다고 주장한다[24]. Zwaan, Langston & Graesser(1995)[23]의 event-indexing 모델은 이를 시간·공간·인물·인과·의도 다섯 축의 연속성 추적으로 구체화한다.




그림 3 국소 이음매 복구 메커니즘 — 추출된 문장만 남기면(좌) 앞뒤 문맥과의 시간·공간·인물·인과적 연결이 끊겨 다리 놓기 추론이 필요한 상태로 남는다. 문장 앞뒤로 한 문장씩 패딩하면(우) 이 연결이 그대로 복원된다. 이 개입은 소설에서 손실을 100%, 판례에서 60% 회복시켰다.

[국소 이음매 복구] 선택된 문장 앞뒤로 한 문장씩 (window=1) 패딩하면 이 다리 놓기 추론(bridging inference)이 그대로 제공된다(그림 3). 소설 79문항 전체에서 이 패딩만으로 RAG와의 정답률 격차가 완전히 해소되었으며(0.278→0.316, 정답률 일치) 토큰 사용량을 절감할 수 있었다(858 대 977). 판례(200문항)에서는 기존 RAG와의 정답률 격차를 60% 축소했다(0.275→0.290). 이 장르별 비대칭은 서사적 특성이 강한 소설 장르의 event-indexing 모델의 연속성 축에 강하게 의존하지만 구조화된 법률 텍스트는 상대적으로 덜 의존하기 때문에 나타난다.

[이론적 함의] 이 결과는 두 이론 사이의 긴장을 재해석하게 한다. 처리수준 이론[20]은 깊은 처리(정교화)가 얇은 처리(유지형)보다 항상 유리하다고 예측하지만 본론 1, 2에서 본 것은 정반대였다. 이는 정교화 되뇌기의 재작성이 처음부터 구조적으로 한계를 지니기 때문이다(RQ2a). 재작성 없이 살아남은 두 전략(검사효과(추출

적·query-aware)와 유지형 되뇌기(추출적·query-agnostic)을 비교하면 장르마다 우세 전략이 다르다(표 5). 이는 Morris, Bransford & Franks (1977)의 전이적 함치리[21](깊이 자체가 아니라 부호화 방식과 인출 요구가 맞아떨어지는지가 기억 성패를 가른다는 이론)와 일치한다. 우열은 부호화 방식이 문서 구조와 인출 요구에 부합하는지에 달려 있다(RQ2b).

표 5 재작성 없이 살아남은 전략들의 장르별 승패

장르	우세 전략	RAG 대비 격차
위키	유지형 되뇌기(동적압축)	+3.0%p (능가)
소설	유지형되뇌기(+복구) = RAG	검사효과만 -20.2%p 로 크게 밀림
뉴스·판례	RAG ≈ 유지형 되뇌기	-0.5%p ~ -1.0%p

이 승패는 장르별 문서 구조 차이와 대체로 맞물린다. 위키는 문서가 짧고 단순해 압축 손실이 작다. 소설은 길고 서사 연속성에 강하게 의존한다. 뉴스·판례는 중간 길이에 서사성이 낮다. 다만 문서 구조만으로 다 설명되지는 않는다. 뉴스는 사전지식이 사실상 없어(1장) 정밀한 사실 인출 자체가 병목이라 RAG와 최종 모델의 격차가 가장 작다($\pm 0.5\%$). 판례는 5지선다 형식·법률 추론의 정밀성에 재조회 역전 현상(6장)까지 겹쳐 절대 정답률이 가장 낮다. 소설은 서사 연속성 의존도가 가장 커 복구 전 격차도, 복구 효과도 가장 컸다. 복구 후엔 RAG와 정답 개수까지 일치했다. 위키는 짧고 단순한 구조 덕에 재작성 없는 유지형 되뇌기가 RAG를 능가하는 유일한 장르가 됐다.

4) 결과: 최종 모델 대 RAG

네 장르를 합산하면(소설·판례는 복구 적용, 위키·뉴스는 격차가 이미 0에 가까워 미적용) 최종 모델은 254/579문항으로 RAG의 254/579문항과 정답 개수까지 정확히 일치한다. 평균 토큰은 3,081로 RAG의 3,588보다 14% 적고 4개 장르 전부에서 RAG와 같거나 더 적다(그림 5). 검사효과를 질문 시점 원문 추출로 구현한 조건도 참고 할 만하다. RAG에 정답률로는 소폭 못 미치지만(0.366, -0.073) 토큰은 5.3배 적고 지연은 34% 짧아 비용에 민감한 배포 환경에서는 다른 트레이드오프를 제공한다.




그림 4 최종 제안 모델과 RAG의 비교: 좌측은 장르별 정답률로, 소설·판례·전체 정답률에서 두 조건이 사실상 동률을 이룬다(전체 0.4387로 정확히 일치). 우측은 동일 정답률에서의 토큰 사용량을 선형축 막대그래프로 비교한 것으로, 최종 제안 모델이 RAG보다 507토큰(약 14%) 적게 쓰며 579문항 전체로 환산하면 약 29만 토큰이 절감된다.

3. 결론

본 연구는 인간 기억 강화 전략이 LLM의 정보 활용을 돕는지를 답하고자 한다(RQ1). 처리수준 이론이 예측한 정교화 되뇌기는 모델 크기와 무관하게 구조적으로 붕괴했지만(RQ2a), 원문을 보존하는 두 전략(검사효과, 유지형 되뇌기)은 생존했지만, 그 우열은 부호화 방식과 문서 구조의 적합도로 갈려(RQ2b) 인간의 인지를 다루는 심리학적 이론인 전이적합처리와 일치했다. 이 진단에서 나온 최종 제안 모델은 RAG와 전체 정답률이 일치하면서 토큰은 14% 절약했다. 복구 효과의 장르별 크기(소설 100%, 판례 60%)가 다리 놓기 추론 이론으로 사전 예측 가능했다는 점에서, 해당 이론이 판정 도구로 활용 가능함을 시사한다.

한계도 있다. 표 2 수치는 1회 실행의 point estimate이며 유의성 검정은 하지 않았다. 판례의 재조회 역전은 범위 효과가 아닌 타케팅 실패에 있었다. 200개 무관 판례의 발췌문을 공유 검색 공간에 두다 보니 Adaptive-k가 근거 청크를 찾는 비율이 7.0%(우연 수준 이하)에 그쳤고, 검색을 건너뛰면 정답률이 0.290~0.300에서 0.560으로 올랐다(간접[30]·부호화 특수성 위반[31]과 일치). 정답률 상한도 한계다: 두 전략 모두 70B teacher를 증류한 t5-small을 썼고[15], 직접 검증한 결과 정교화 되뇌기는 용량이 원인이 아니었으나(압축기를 키우자 0.339→0.212로 악화) 유지형 되뇌기는 용량이 선택 품질을 높였다(RoBERTa-large: MAP 0.493→0.584, 다만 QA 효과는 장르에 의존적이라 RoBERTa-base를 주 결과로 유지).

최종 모델의 성과에도 한계가 존재한다. RAG의 성능을

실질적으로 능가하지는 못했기에, 실질적 이점은 토큰 14% 절감이라는 효율성이다. 최근 문헌이 보고하는 컨텍스트 절반 지점의 급격한 붕괴[26]는 75,000~90,000단 어까지 확장해도 나타나지 않았다(0.583~0.556, 5만 단어 대비 -2.8%p 이내). 또한 다단계 추론·sufficient-context 증화, QwenLong-CPRS[27]·ArcAligner[28]·TiMem[29] 같은 정교한 압축 메커니즘과의 비교는 검증하지 않았다.

향후 연구로 더 큰 base 모델 재학습, 교정 재시도 메커니즘의 전체 규모 검증, extractive 조건의 국소 복구 적용, teacher gist 기반 압축기 품질 상한 확정을 계획한다.

참고 문헌

1. C. Wang, J. V. Sun, "Unable to Forget: Proactive Interference Reveals Working Memory Limits in LLMs Beyond Context Length," ICML Workshop on Long Context Foundation Models, 2025.
2. "Memory for Autonomous LLM Agents: Mechanisms, Evaluation, and Emerging Frontiers," arXiv preprint, 2026.
3. Y. Jung et al., "Context-Driven Incremental Compression for Multi-Turn Dialogue Generation," ICML, 2026.
4. K.-H. Lee et al., "A Human-Inspired Reading Agent with Gist Memory of Very Long Contexts," ICML, 2024.
5. Q. Wang et al., "Recursively Summarizing Enables Long-Term Dialogue Memory in Large Language Models," Neurocomputing, 2025.

6. H. Yu et al., "MemAgent: Reshaping Long-Context LLM with Multi-Conv RL-based Memory Agent," arXiv preprint, 2025.
7. M. A. Hearst, "TextTiling: Segmenting Text into Multi-paragraph Subtopic Passages," Computational Linguistics, 1997.
8. C. Taguchi et al., "Efficient Context Selection for Long-Context QA: No Tuning, No Iteration, Just Adaptive-k," EMNLP, 2025.
9. T. Kočíský et al., "The NarrativeQA Reading Comprehension Challenge," Transactions of the ACL (TACL), 2018.
10. I. Chalkidis et al., "LexGLUE: A Benchmark Dataset for Legal Language Understanding in English," ACL, 2022.
11. P. Rajpurkar et al., "SQuAD: 100,000+ Questions for Machine Comprehension of Text," EMNLP, 2016.
12. A. Trischler et al., "NewsQA: A Machine Comprehension Dataset," RepL4NLP Workshop (ACL), 2017.
13. Y. An et al., "Enhancing Student Learning with LLM-Generated Retrieval Practice Questions: An Empirical Study in Data Science Courses," arXiv preprint, 2025.
14. T. Zhang et al., "TriggerBench: Investigating Prospective Memory for Large Language Models," arXiv preprint, 2026.
15. J. H. Cho, B. Hariharan, "On the Efficacy of Knowledge Distillation," ICCV, 2019.
16. Rehearse, Then Recall (repository). Available: <https://github.com/lucytheboss/rehearse-then-recall>
17. J. Kim et al., "EXIT: Context-Aware Extractive Compression for Enhancing Retrieval-Augmented Generation," Findings of ACL, 2025.
18. H. Jiang et al., "LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression," ACL, 2024.
19. P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," ICLR, 2024.
20. F. I. M. Craik, R. S. Lockhart, "Levels of Processing: A Framework for Memory Research," Journal of Verbal Learning and Verbal Behavior, 1972.
21. C. D. Morris et al., "Levels of Processing versus Transfer Appropriate Processing," Journal of Verbal Learning and Verbal Behavior, 1977.
22. W. Kintsch, "The Role of Knowledge in Discourse Comprehension: A Construction-Integration Model," Psychological Review, 1988.
23. R. A. Zwaan et al., "The Construction of Situation Models in Narrative Comprehension: An Event-Indexing Model," Psychological Science, 1995.
24. H. H. Clark, S. E. Haviland, "Comprehension and the Given-New Contract," in Discourse Production and Comprehension, R. O. Freedle, Ed. Norwood, NJ: Ablex, 1977.
25. A. Laitenberger et al., "Stronger Baselines for Retrieval-Augmented Generation with Long-Context Language Models," EMNLP, 2025.
26. W. Wang et al., "Intelligence Degradation in Long-Context LLMs: Critical Threshold Determination via Natural Length Distribution Analysis," arXiv preprint, 2026.
27. W. Shen et al., "QwenLong-CPRS: Towards ∞ -LLMs with Dynamic Context Optimization," arXiv preprint, 2025.
28. J. Li et al., "ArcAligner: Adaptive Recursive Aligner for Compressed Context Embeddings in RAG," arXiv preprint, 2026.
29. K. Li et al., "TiMem: Temporal-Hierarchical Memory Consolidation for Long-Horizon Conversational Agents," Findings of ACL, 2026.
30. J. R. Anderson, "Retrieval of Propositional Information from Long-Term Memory," Cognitive Psychology, 1974.
31. E. Tulving, D. M. Thomson, "Encoding Specificity and Retrieval Processes in Episodic Memory," Psychological Review, 1973.